自动化风险投资：使用 LLM 驱动的分层、特征工程与自动标注技术进行创始人评估

Ekin Ozince；Yiğit Ihlamur

目录

摘要 2

1 引言 2

2 方法 3

2.1 数据集 3

2.2 特征工程 3

2.2.1 教育数据处理 3

2.2.2 创始人摘要 4

2.2.3 层级分层 4

2.2.4 人设分层 6

2.2.5 额外的布尔标记 7

2.3 通过机器学习预测成功 8

3 结果与评估 9

3.1 层级分层 9

3.2 人设分层 9

3.3 额外布尔标记 9

3.4 机器学习模型 9

4 讨论 13

4.1 结论 13

4.2 局限性与未来方向 13

参考文献 13

附录 14

A.1 创始人摘要 14
A.1.1 提示词 14
A.1.2 输出示例 16
A.2 层级分层提示词 17
A.2.1 提出新层级 17
A.2.2 按层级给创始人打标 18
A.3 人设分层提示词 21
A.3.1 按人设给创始人打标 21
A.4 布尔标记提示词 22
A.4.1 布尔标记打标 22
该文献的主要观点 23

摘要

本研究探讨了大语言模型（LLM）在风险投资（VC）决策中的应用，重点关注基于创始人特征预测初创企业成功的可能性。我们利用链式思维等 LLM 提示技术，在有限数据的基础上生成特征，随后结合统计分析与机器学习方法提取洞见。研究结果表明，某些创始人特征可能与企业成功存在关联，同时也证明了这些特征在预测任务中的有效性。将机器学习技术与 LLM 融合的这一框架，在提升初创企业成功预测方面具有广阔潜力，并对希望优化投资策略的风险投资机构具有重要意义。

1 引言

对于风险投资机构而言，识别那些在早期阶段就具备较高成功潜力的初创企业至关重要。但由于影响结果的变量极其繁多，这一任务本身非常困难。随着机器学习（ML）工具不断演进，它们为补充 VC 基金的分析能力、改进投资策略提供了重要机会。与此同时，日益流行的大语言模型（LLM）也能够通过快速提取原本难以解析的数据洞见，为这一过程提供支持。

本文旨在介绍利用机器学习与大语言模型预测新创始人成功可能性的若干路径。我们借助 LLM，在仅有有限创始人数据的条件下提出并构造新特征，这些数据模拟了风险投资机构在考虑是否资助一家公司时通常能够获得的信息。随后，我们利用这些特征来提取洞见并预测初创企业是否成功，从而展示 LLM 在这一领域的巨大潜力。

2 方法

2.1 数据集

原始数据集由两个 CSV 文件组成，分别包含 1022 名成功创业者和 2694 名不成功创业者的信息。这些创始人均位于美国，且其创办公司成立于 2010 年或之后。本文中，“成功”指创始人创办的公司满足以下任一条件：完成首次公开募股（IPO）且估值超过 5 亿美元；以超过 5 亿美元的价格被收购；或累计融资超过 5 亿美元且目前仍在运营。

原始数据中我们重点关注的变量包括 linkedin json（创始人 LinkedIn 档案中的全部信息，以 JSON 格式存储）以及 org name（创始人所创公司的名称）。这两个变量的使用方式将在后文进一步说明。

为开展创始人成功预测，我们将原始两个 CSV 文件合并为一个 pandas dataframe，并新建一个名为 success 的布尔标记列，用于区分成功与不成功的创始人。为便于 LLM 处理，我们从中随机抽取了一个子样本，包含 150 名成功创始人与 150 名不成功创始人。需要说明的是，缺失 LinkedIn 档案或 JSON 数据格式错误的行被有意排除在抽样之外。

2.2 特征工程

从原始数据中构造特征涉及多个步骤，包括通过代码解析数据，以及使用 LLM，具体而言是 OpenAI 的 GPT-4o，提取关键信息。

2.2.1 教育数据处理

起初，我们采用了较为传统的技术手段，从每位创始人的 LinkedIn 数据中提取教育信息。首先，我们解析 LinkedIn 数据，以识别每位创始人获得的各项学位，并据此编码变量 highest_edu，用于表示创始人的最高学历。各教育层次与整数的映射关系如表 1 所示。[1]

随后，我们继续解析 LinkedIn 数据，以识别每位创始人的专业领域。不同的学科类别也被映射为不同整数，如表 2 所示。[2] 由于同一位创始人可能修读多个领域，因此这些信息以整数集合的形式存储在变量 fields_of_study 中。尽管许多创始人跨多个领域学习，但也有一部分创始人由于教育数据有限而被赋予空集合。

学位	映射值
无学位或未知	0
学士（BA、BS 等）	1
硕士（MA、MS、MBA 等）	2
博士（PhD、MD、JD 等）	3

表 1：学位映射

研究领域	映射值
数学、定量领域等	0
生物学、化学、医学、心理学、生理学、解剖学、免疫学、遗传学等	1
会计、银行、精算、金融、经济学等	2
商业、管理、创业、领导力等	3
销售、分销、市场营销等	4
计算机科学/工程、机器学习、人工智能、人机交互等	5
英语、媒体、电影、历史、新闻、哲学、文科/视觉艺术等	6
政治学、社会学、法律、咨询等	7
建筑、设计、城市规划等	8
工程学、机器人、物理学等	9

表 2：研究领域映射

2.2.2 创始人摘要

特征工程的其余部分大量使用了 LLM 与提示技术，首先是为每位创始人生成摘要。给定某位创始人的 LinkedIn 数据及其最新创办公司的名称后，我们提示 LLM 生成一份关于该创始人的详细摘要，其中包括其教育背景、所在地、技能和工作经历。提示中特别强调，模型应聚焦于创始人创办当前公司之前的时期，因为在真实情境下，风险投资人评估一位新创始人时，通常只能获得这些信息。

在这里，我们采用了少样本提示（few-shot prompting）方法，即在提示中提供示例，以引导模型生成我们期望的输出。[3] 提示中给出了摘要的一般结构，以及某位具体创始人的示例摘要。[4] 我们还要求 LLM 在网络上搜索补充信息，例如创始人此前所创公司当前的状态等。具体使用的提示词和一份模型输出示例见附录。

2.2.3 层级分层

层级生成

既有研究[5] 将初创企业创始人划分为五个不同类别，从 L1 到 L5，用以描述创始人在与创业成功相关的经验与成就方面所处的层级。为了获得更细致的洞见，我们采用一种基于 LLM 的无监督方法，将分层粒度从五级细化为十级。

我们向 LLM 输入 50 份创始人摘要（见上一节），并要求其在既有五级分类的基础上提出一个新的十级分类列表。提出十级分类所使用的具体提示词见附录。

之后，我们对这十级分类的描述进行了进一步润色，以提高分类的明确性以及 LLM 产出正确结果的能力。各层级定义如下：

• Level 10（L10）：连续创业者，曾成功创办并退出多家公司，且每家公司都获得了大量融资和高估值，通常在 1 亿美元以上，并能持续成功地将公司扩展至 IPO 或大型退出。

• Level 9（L9）：在创办当前公司之前，曾领导过独角兽企业（估值超过 10 亿美元）的创业者。

• Level 8（L8）：以突破性创新著称的创始人，曾显著颠覆现有市场或开创新市场，且往往被视为科技行业中的思想领袖。

• Level 7（L7）：曾将初创企业从种子阶段扩展到中后期，获得大额融资（5000 万至 1 亿美元），并为潜在 IPO 或重大退出奠定基础的创始人。

• Level 6（L6）：曾有中大型退出经历，且可能在知名科技公司担任过关键高管职务的创始人。

• Level 5（L5）：此前创办的公司已获得大量融资（超过 1 亿美元）且尚在推进 IPO 的创始人。

• Level 4（L4）：曾有小型到中型成功退出经历，或在知名科技公司担任过重要职务的创始人。

• Level 3（L3）：拥有 10 至 15 年技术和管理经验的个体，包括在高速成长科技公司或独角兽企业担任重要角色者；也可能包括在相关领域拥有博士学位的学术人士。

• Level 2（L2）：在创办当前公司之前已有数年初创经验的创始人，可能毕业于知名加速器项目。

• Level 1（L1）：相对刚进入科技行业的创始人，可能经验有限，但展现出较高潜力。

按层级对创始人进行分类

在最终确定上述层级后，我们采用提示链（prompt chaining）方法，将先前生成的创始人摘要输入 LLM，使其将每位创始人归入上述某一层级。随后，我们通过统计每个层级中被判定为成功的创始人数，计算基于层级的成功率。

这一过程采用了链式思维（CoT）提示，并在少样本提示基础上进一步扩展。少样本 CoT 指在提示中同时给出输入、输出及推理过程示例，以引导 LLM 按照类似方式生成结果。[6] 用于标注的具体提示词见附录。[7]

2.2.4 人设分层

人设生成

人设分层的流程与层级分层基本相同。既有研究[8]使用了十种人设，用于描述除层级分层所覆盖信息之外的创始人关键特征。与前一节类似，我们采用几乎相同的无监督方法，向 LLM 提供既有人设类别与 50 份创始人摘要，并要求其提出一个由二十种人设构成的新列表。

在对措辞进行调整以获得更好结果之后，最终的人设类别如下：

（A）成功的连续创业者，曾打造出一家上市公司。

（B）成功的连续创业者，曾将某家公司以超过 1 亿美元的规模退出。

（C）刚毕业即创业，大学毕业当年或一年内即创办公司的创业者。

（D）首次创业者，在大学毕业后 3 至 5 年内创办公司。

（E）创始人拥有博士学位，或曾经/正在从事研究工作，或曾在大学任教。

（F）首次创业的非科技背景创业者，在非科技行业拥有 10 年以上经验。

（G）在科技公司任职超过 10 年的科技高管。

（H）曾在独角兽公司担任工程师或高管。

（I）在科技公司担任过工程师或产品经理的创始人。

（J）拥有 MBA 学位的创始人。

（K）曾在多个国家生活或工作的创始人。

（L）此前至少创办过两家公司以上的连续创业者。

（M）来自企业背景，但总工作经验不足 10 年的创始人。

（N）具有金融、会计或经济学背景的创始人。

（O）从艺术/人文学科转向科技创业的创始人。

（P）在非营利组织或社会创业领域有经验的创始人。

（Q）曾在所属行业获得显著奖项或认可的创始人（如《福布斯》30 位 30 岁以下精英）。

（R）具有军旅经历的创始人。

（S）在男性主导行业中取得显著成就的女性创始人。

（T）不属于上述类别的其他创始人。

需要承认的是，使用无监督的大语言模型提示技术可能会生成带有偏见的人设类别，例如（R）。出于研究目的，我们选择如实呈现无监督技术生成的输出。这种透明处理旨在为今后 AI 建模技术的发展提供有价值的启示，尤其是在提示构造中加强伦理护栏设计方面。

按人设对创始人进行分类

同样地，我们再次采用提示链与少样本 CoT 提示，为数据集中每位创始人生成人设标签。[9] 完整提示见附录。

与层级分层不同，创始人可以被赋予多个人设。因此，该变量在数据中记录为多个布尔列，每列对应一个可能的人设。随后，研究对各类人设的成功率进行了分析。

2.2.5 额外的布尔标记

布尔标记生成

为捕捉有关创业者的更多信息，我们向数据集中加入了 23 个布尔变量。这些变量首先通过头脑风暴初步确定，随后借助与前文类似的 LLM 提示过程加以完善。

这 23 个布尔标记如下：

• is_firsttime_founder：若创始人仅创办过一家公司，则取 1；若创始人创办过不止一家公司，则取 0。

• is_researcher：若创始人在创办公司之前从事过研究工作，则取 1；否则取 0。

• is_phd：若创始人在创办公司之前获得过博士学位或类似博士层级学位，则取 1；否则取 0。

• is_scholarship：若创始人在创办公司之前曾获得重要奖学金（例如 Fulbright Scholar），则取 1；否则取 0。

• is_young_grad：若创始人在大学毕业一年内创办公司，则取 1；否则取 0。

• is_dropout：若创始人在创办公司之前曾从大学辍学，则取 1；若未辍学，则取 0。

• top_tier_uni：若创始人在创办公司之前毕业于 QS 世界大学排名前 50 的高校，则取 1；否则取 0。

• multiple_degrees：若创始人在创办公司之前取得过多个学位，则取 1；否则取 0。

• entrepreneurship_education：若创始人在创办公司之前学习过创业学或参加过创业项目（如孵化器、加速器），则取 1；否则取 0。

• few_years_experience：若创始人在创办公司之前拥有 1 至 5 年工作经验，则取 1；否则取 0。

• decade_experience：若创始人在创办公司之前拥有 10 年或以上工作经验，则取 1；若不足 10 年，则取 0。

• big_tech_experience：若创始人在创办公司之前曾在大型科技公司（NVIDIA、Google、Meta、Apple、Amazon 或 Microsoft）工作，则取 1；否则取 0。

• comm_experience：若创始人在创办公司之前有市场营销、公共关系或相关领域经验，则取 1；否则取 0。

• exec_experience：若创始人在创办公司之前曾担任高级管理岗位（如 CEO、COO、CTO、VP、President），则取 1；否则取 0。
• is_investor：若创始人在创办公司之前从事过投资工作（如风险投资、天使投资），则取 1；否则取 0。
• is_board_member：若创始人在创办公司之前曾担任董事会成员，则取 1；否则取 0。
• international_uni：若创始人在创办公司之前曾就读于美国以外的大学，则取 1；否则取 0。
• lived_multiple_countries：若创始人在创办公司之前曾在多个国家生活（例如在多个国家求学，或在不同国家工作），则取 1；否则取 0。
• has_job_hopped：若创始人在创办公司之前频繁更换雇主（每 1 至 2 年更换一次），则取 1；否则取 0。
• has_promotions：若创始人在创办公司之前曾在同一工作单位获得晋升（例如职业经历显示其岗位随时间发生变化），则取 1；否则取 0。
• is_top_tier_consultant：若创始人在创办公司之前曾就职于大型管理咨询公司（如 McKinsey & Company、BCG），则取 1；否则取 0。
• is_top_tier_banker：若创始人在创办公司之前曾在顶级银行（如 Goldman Sachs）任职，则取 1；否则取 0。
• founded_under_30：若创始人在 30 岁之前创办公司，则取 1；否则取 0。此项可依据毕业年份等可获得信息估算创办时年龄。

应用布尔标记

每位创始人的布尔标记值是通过少样本提示方式生成的，具体做法是向 LLM 输入 50 份创始人摘要。随后，我们分别对每个布尔变量取 True 或 False 时的成功率进行计算。用于标注的提示词缩略版本见下文附录。

2.3 通过机器学习预测成功

在围绕创始人的教育背景、创业层级、人设等信息构造出数值变量后，我们训练了三种机器学习模型，以根据这些变量对创始人的成功与否进行分类：线性回归、随机森林以及 XGBoost。

这些模型在 240 个样本上进行训练，并在两个独立测试集上进行测试，以模拟风险投资基金可能面临的不同情境。第一个测试集包含 28 名不成功创始人和 2 名成功创始人；第二个测试集则各包含 15 名。随后，我们使用准确率、精确率等性能指标来评估并比较这些模型的效果。

3 结果与评估

3.1 层级分层

各层级的总样本数及四舍五入后的成功率见表 3。可以看到，L1 至 L4 的成功率均低于 50%，而其余层级均高于 50%。这一结果是合理的，因为被归入更高层级的创始人通常拥有更丰富的创业经验。L5、L9 与 L10 的成功率达到 100%，但其中 L5 与 L10 的样本数据极少。相比之下，L9（曾领导独角兽企业的创始人）达到 100% 成功率这一结果仍值得关注。

3.2 人设分层

表 4 总结了各类人设的总样本数和成功率。由于每位创始人可以被赋予多个不同人设，因此总计数会超过整体样本量。值得注意的是，人设 P（曾在非营利组织任职的创始人）的成功率为 0%；而人设 Q（获得过显著奖项的创始人）与 R（具有军事服役背景的创始人）的成功率均达到或超过 90%，表明这些特征可能是创业者身上值得关注的优点。

3.3 额外布尔标记

表 5 展示了部分布尔变量的总样本数及四舍五入后的成功率。为简洁起见，仅列出 True 与 False 两种取值之间成功率差异超过 5 个百分点的变量。其中，差异最大的变量是 is_dropout、is_top_tier_consultant 和 is_top_tier_banker，但这些变量在 True 取值下的数据样本都很少。

3.4 机器学习模型

表 6 比较了所测试三类模型的性能指标。如前所述，测试集 1 包含 28 名不成功创始人和 2 名成功创始人，测试集 2 则各包含 15 名。

准确率（Accuracy）是指整个测试集中预测正确的比例。精确率（Precision）衡量的是在所有被预测为正类的样本中，真正正类所占的比例，也就是在风险投资语境下，VC 所支持的初创公司中最终真正成功的比例。F1 分数通过对准确率和精确率取调和平均来综合评估预测性能。最后，TPR 表示真正率（True Positive Rate），其定义为：

真阳性 /（真阳性 + 假阴性）。

在本文语境下，该指标表示 VC 基金从全部成功创始人中识别并挑选出来的比例。

总体来看，根据这些指标，在线性回归模型在“28 名不成功、2 名成功”的不平衡测试集中表现更好，而在均衡测试集上，其余模型表现更佳。随机森林模型整体上也优于 XGBoost。

在这些指标中，精确率可能是风险投资场景中最重要的指标，因为 VC 基金的核心目标之一就是最大化投资组合中成功创业项目的占比。从这一标准来看，最佳模型会随预测数据集的构成而改变。当数据中成功创始人占比较少时，线性回归表现最佳，精确率达到 18.2%；而在更均衡的数据集中，随机森林则非常有效，精确率达到 70.6%。

层级	总样本数	成功率（%）
L1	16	37.5
L2	57	35.1
L3	58	29.3
L4	79	40.5
L5	1	100
L6	37	64.9
L7	14	92.9
L8	12	91.7
L9	25	100
L10	1	100

表 3：各层级成功率

人设	总样本数	成功率（%）
A	41	56.1
B	21	71.4
C	6	50.0
D	38	44.7
E	56	60.7
F	96	43.8
G	28	50.0
H	19	57.9
I	73	63.0
J	81	42.0
K	31	54.8
L	87	51.7
M	11	27.3

N	52	48.1
O	9	22.2
P	9	0.0
Q	5	100.0
R	10	90.0
S	6	16.7
T	11	45.5

表 4：各人设成功率

变量	**总样本数**	**成功率（%）**
is_researcher（否）	232	46.98
is_researcher（是）	68	60.29
is_phd（否）	241	47.72
is_phd（是）	59	59.32
is_scholarship（否）	297	49.83
is_scholarship（是）	3	66.67
is_young_grad（否）	295	50.17
is_young_grad（是）	5	40.00
is_dropout（否）	298	49.66
is_dropout（是）	2	100.00
top_tier_uni（否）	178	41.57
top_tier_uni（是）	122	62.30
entrepreneurship_education（否）	280	51.07
entrepreneurship_education（是）	20	35.00
few_years_experience（否）	154	45.45
few_years_experience（是）	146	54.79
decade_experience（否）	174	54.02

decade_experience（是）	126	44.44
big_tech_experience（否）	270	47.04
big_tech_experience（是）	30	76.67
comm_experience（否）	246	54.88
comm_experience（是）	54	27.78
exec_experience（否）	105	45.71
exec_experience（是）	195	52.31
is_investor（否）	259	48.26
is_investor（是）	41	60.98
is_top_tier_consultant（否）	292	49.32
is_top_tier_consultant（是）	8	75.00
is_top_tier_banker（否）	293	49.49
is_top_tier_banker（是）	7	71.43
founded_under_30（否）	207	47.83
founded_under_30（是）	93	54.84

表 5：部分布尔变量的成功率

模型	**准确率**	**精确率**	**F1 分数**	**TPR**
线性回归（测试集 1）	0.700	0.182	0.308	1.000
线性回归（测试集 2）	0.567	0.571	0.552	0.533
随机森林（测试集 1）	0.667	0.100	0.167	0.500
随机森林（测试集 2）	0.733	0.706	0.750	0.800
XGBoost（测试集 1）	0.667	0.100	0.167	0.500
XGBoost	0.667	0.647	0.688	0.733

（测试集 2）				

表 6：模型性能指标比较

4 讨论

4.1 结论

本文为预测初创企业成功而构造的特征，即企业以某种形式达到 5 亿美元估值这一结果，显示出相当可观的潜力。当这些特征被输入模型后，本文所考察的所有机器学习模型都表现相对良好，尤其是在风险投资和投资决策的语境中。此外，不同创始人分类的成功率差异，例如具有军事背景的创始人所表现出的较高成功率，也暗示了某些创始人特征与其将初创企业扩张做大的能力之间可能存在值得关注的联系。

4.2 局限性与未来方向

本研究在抽样与预测过程中存在一个局限，即创始人是作为单独个体来考察的，而不论其创办公司时是否有联合创始人。我们在预测创业成功时，默认给定个体是公司的唯一创始人。然而，整个创始团队的特征很可能都会影响一家初创企业的成功，因此对于多创始人公司而言，我们模型的预测能力可能会受到限制。

另一项局限来自大语言模型本身的可靠性。尽管研究初期曾对部分 LLM 输出进行人工审核，以确保其正确性并在需要时调整提示词，但样本中的全部 300 个实例并未逐一接受这种检查。这在一定程度上限制了我们对结果的信心。例如，LLM 输出的创始人总工作年限可能并不准确。模型是通过将创始人历任工作的任职时长相加来计算这一数值的，但部分工作经历之间可能存在时间重叠，这会导致其职业总年限被高估。

本研究还有一个附带发现，即其中一个人设类别（S）与创始人是否为女性有关。该人设是在无人为干预的无监督过程中生成的。我们在本文中保留这一类别，是为了提示 LLM 在自主决策时可能出现的问题。随着越来越多的机构引入自治式 AI 代理来增强其投资决策流程，这一点尤为重要。

未来研究应当通过考虑联合创始人之间特征的交互作用，并进一步优化提示策略，来解决上述局限。未来研究还可以考察不同特征在决定初创企业成功方面的重要程度。本文中的成功率分析以及既有研究都持续表明，相较于其他特征，仍然存在许多更隐蔽、但与成功密切相关的变量。因此，这一研究方向值得进一步深入推进。

参考文献

Suyal, A., & Ihlamur, Y. (2024). Utilizing language model driven founder segmentation for predicting entrepreneurial success [Unpublished research paper].

Touvron, H., Lavril, T., Izacard, G., Martinet, X., Lachaux, M.-A., Lacroix, T., Rozière, B., Goyal, N., Hambro, E., Azhar, F., Rodriguez, A., Joulin, A., Grave, E., & Lample, G. (2023). Llama: Open and efficient foundation language models.

Wang, X., & Ihlamur, Y. (2024). An automated startup evaluation pipeline: Startup success forecasting framework (SSFF).

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Ichter, B., Xia, F., Chi, E., Le, Q., & Zhou, D. (2023). Chain-of-thought prompting elicits reasoning in large language models.

Xiong, S., & Ihlamur, Y. (2023). Founder-GPT: Self-play to evaluate the founder-idea fit.

附录

A.1 创始人摘要

A.1.1 提示词

'''

查看下方以 ### 分隔的数据。这些数据描述了一位初创企业创始人。

###

{linkedin_json}

###

此人最新创办的公司是 {org_name}。

你的任务是根据这些数据生成一份详细且准确的摘要。摘要应当简明扼要，并具备以下属性：

第一句话说明该个人的姓名和当前所在地。然后说明此人最新创办的公司 {org_name}，以及其创办该公司的年份。接着总结此人的教育背景。

请逐项提及：每所院校、学位类型、专业、学习时间段，以及院校所在地。

接下来转入工作经历部分。此处应简要描述该个人在创办 {org_name} 之前担任过的每一份工作。

描述应包含：其工作的公司名称、雇主名称、职位名称、时间段（从 DD-MM-YYYY 到 DD-MM-YYYY）、任职时长（按年计算），以及可获得时的地点信息。

应排除该个人在创办 {org_name} 之后才开始的工作。

接着，突出该个人的技能。

若该信息缺失，则使用描述字段提取相关技能。

上述所有细节都必须包含。

请将以上输出写成一个段落。

最后，补充以下三个问题：

1）创始人就读过的大学，以及它们在最新 QS 世界大学排名中的全球名次（大学，#排名）：

$Answer1$

2）该个人在创办 {org_name} 之前的总工作经验时长（按年）。

在这一部分中，请将前面所述各段工作经历的任职时长相加。

$Answer2$

3）他们在创办 {org_name} 之前创办/联合创办过的公司，格式为：公司，状态，美元净值。

（请上网搜索公司的准确净值数据。）

$Answer3$

请按照所提供的信息格式作答。

在问题 3 中，排除 {org_name}，因为这是其最新创办的公司。

另外在问题 4 中，与 status 和 net worth in USD 相关的字段应从给定的雇主信息中获取。

对于财务数字，千位表示为 “K”，百万表示为 “M”，并仅保留一位小数。

例如，20,500 美元写为 “20.5K”，50,700,000 美元写为 “50.7M”。

以下是一个示例：

XXXXX，男性，目前居住在美国加利福尼亚州圣迭戈。

他最新创办的公司是 10x Genomics，于 2012 年联合创办。

他拥有广泛的教育背景，包括在加州大学圣迭戈分校获得生物工程与生物医学工程博士学位，

并在该校完成生物工程硕士和生物工程学士学位。

他总共拥有 3 段教育经历，累计时长 14 年。

在职业生涯中，在创办 10x Genomics 之前，

XXXXX 曾于 2005-2008 年担任 Lawrence Livermore National Lab 的研究科学家，时长 3.92 年；

于 2002-2008 年担任 Lawrence Livermore National Laboratory 的生物物理学家，时长 6 年；

于 2011-2012 年担任 Bio-Rad Laboratories, Inc. 的高级首席科学家，时长 0.5 年。

他还联合创办了 Quantalife，并于 2008-2011 年担任首席科学官，时长 3.16 年。

他的技能涵盖肌肉力学到初创企业管理，并包括生物医学工程、分子生物学和领导力等专长。

Tangney 还发表了大量与心脏力学和心肌功能相关的文章。

1）曾就读的大学及其最新 QS 世界大学排名（大学，#排名）：

加州大学圣迭戈分校，#53。

2）该个人在创办 {org_name} 之前的总工作经验（按年）：

13.58 年。

3）其在创办 10x Genomics 之前创办/联合创办的公司，格式为：公司，状态，美元净值：

Quantalife，已关闭，30.1M。

'''

A.1.2 输出示例

'''

XXXXX 目前居住在美国加利福尼亚州旧金山。

他于 2012 年 6 月联合创办 Airtable。

他拥有较强的教育背景，于 2004 至 2008 年就读杜克大学，

获得电气与计算机工程、经济学 BSE 学位。

在创办 Airtable 之前，XXXXX 曾担任多个重要职位：

1. Google：2009 至 2012 年担任产品经理，领导 Google Maps 新界面团队，负责影像与 3D 交互，并管理 Android 上的社交应用。时长 3 年。

2. Accenture：2008 年 8 月至 2009 年 8 月任 Technology Labs Development Group 成员，设计并构建多个原型，包括企业级 iPhone 应用和网页优化/分析平台。时长 1 年。

3. Scripps Institution of Oceanography：2006 年 5 月至 8 月担任工程研究实习生，参与多项工程研究项目。时长 0.33 年（约 4 个月）。

根据这些工作描述，可以推断 XXXXX 具备产品管理、软件开发、社交应用（如 Facebook、Twitter 集成）、

企业应用设计、网页优化以及软件应用中的 3D 交互等技能。

1）创始人就读过的大学及其最新 QS 世界大学排名（大学，#排名）：

Duke University，#50。

2）该个人在创办 Airtable 之前的总工作经验（按年）：

4.33 年。

3）其在创办 Airtable 之前创办/联合创办过的公司，格式为：公司，状态，美元净值：

无可用信息。

'''

A.2 层级分层提示词

A.2.1 提出新层级

'''

查看下方以 ### 分隔的列表。

###

{summaries}

###

这是一个由字符串构成的列表，以逗号分隔，每个字符串都是对一位初创企业创始人的描述。

我们希望将每位创始人划分到十个不同类别之一。

当前我们只有五个类别，定义如下（见 $$$），本任务将在其基础上扩展。

$$$

Level 5 (L5): 企业家，其公司已获得 1 亿美元以上融资，正处于 IPO 进程中。

Level 4 (L4): 企业家，曾有小型到中型退出经历，或曾在知名科技公司担任高管。

Level 3 (L3): 具有 10 至 15 年技术与管理经验（如在大科技公司、独角兽企业工作，或拥有博士学位）。

Level 2 (L2): 有若干年经验的创业者，或加速器项目毕业生。

Level 1 (L1): 与科技圈联系较少，或经验极其有限但潜力较大的创业者。

$$$

你的任务是分析 ### 中的描述列表，提出十个类别，用于根据创始人的工作经历与创业经历对其进行分类。

这十个类别应与 $$$ 中现有类别相似，但在其基础上进一步扩展。

'''

A.2.2 按层级给创始人打标

'''

请充分理解并分析 ### 中给出的层级分类。

这些分类将用于后续对创始人的层级划分。

###

Level 10 (L10)

- 连续创业者，拥有多个 1 亿美元以上退出案例：成功创办并退出多家公司，每家公司都获得大量融资与高估值，通常超过 1 亿美元，并持续成功地把公司扩展至 IPO 或大型退出。

- 示例：曾推动多家公司上市，或以数亿美元价格出售这些公司的创始人。

Level 9 (L9)

- 曾拥有独角兽创业经历的创始人：在创办当前公司之前，曾领导过独角兽企业（估值 > 10 亿美元）。

- 示例：曾任高知名度、估值超过 10 亿美元初创公司的 CEO。

Level 8 (L8)

- 技术远见者与行业创新者：以突破性创新著称，显著颠覆或开创新市场，且常被视为科技行业思想领袖。

- 示例：推出革命性产品、重塑行业格局的创始人（例如接近 Elon Musk 级别的创新者）。

Level 7 (L7)

- 高增长扩张型创业者：曾将初创公司从种子阶段扩展到中后期，融资达到 5000 万至 1 亿美元，并为潜在 IPO 或重大退出铺路。

- 示例：曾运营快速增长的中型初创公司的创业者。

Level 6 (L6)

- 具有稳健退出历史的重要高管：曾有中型到大型退出经历，且可能在知名科技公司担任关键高管，通常拥有深厚行业经验。

- 示例：在知名科技公司任高管，且出售过自己创办公司的创业者。

Level 5 (L5)

- 成长阶段、等待 IPO 的创业者：此前创办的公司已获得 1 亿美元以上融资，且正在推进 IPO。

- 示例：某家即将上市公司的前 CEO。

Level 4 (L4)

- 具有中型退出或知名岗位经历的创始人：曾有小型到中型成功退出，或在知名科技公司担任重要角色。

- 示例：有 5000 万美元以上退出记录，或曾任知名科技公司高级高管。

Level 3 (L3)

- 行业深耕型技术专家：拥有 10 至 15 年技术和管理经验，包括在高速增长科技公司或独角兽企业担任重要职务；也可包括相关领域博士。

- 示例：独角兽企业的高级工程师/技术负责人，或拥有相关行业专利的博士。

Level 2 (L2)

- 早期创业者或加速器校友：在创办当前公司之前拥有几年初创经验，可能毕业于知名加速器项目，并在创业中展现出初步潜力。

- 示例：参加过 Y Combinator 或其他知名加速器的创始人。

Level 1 (L1)

- 新近起步但具有潜力的创始人：相对刚进入科技行业，经验可能有限，但表现出较高潜力和抱负。

- 示例：刚毕业不久、履历有限但有创新想法的创业者。

###

请想象一个由 3 位资深风险投资分析师组成的委员会，他们将审阅创始人的详细背景与成就摘要。

步骤如下：

分析师先独立审阅数据，记录所有可能影响最终评估和层级划分的关键细节。

然后，每位分析师根据其专业判断，独立给出最匹配的创始人层级，并给出清晰理由。理由必须由事实和数字支持，以确保定量且准确。

随后，三位分析师会相互分享各自的层级判断。若三人一致，则该结果即为最终结论；若不一致，则轮流解释理由，直到达成共识。

为避免幻觉，不要受之前查询影响。

最终将生成一份总体报告，包含每位分析师的分析、所分配的层级，以及相应理由。

请对下面给出的创始人摘要进行类似分析。

输出应当只有层级结果，例如 “L10”。

'''

{summary}

'''

'''

A.3 人设分层提示词

A.3.1 按人设给创始人打标

'''

用于根据创始人摘要，将创始人划分到 20 种人设（A 到 T）之一的提示词如下：

请充分理解并分析 ### 中给出的人设分类。

这些分类将用于后续对创始人的人设划分。

###

(A) 成功的连续创业者，打造过上市公司。

(B) 成功的连续创业者，曾有公司以超过 1 亿美元退出（可在 Google 搜索其创办公司的融资情况以获取更准确数据）。

(C) 刚毕业就创业，在大学毕业当年或一年内创办公司。

(D) 首次创业者，在大学毕业后 3 至 5 年内创办公司。

(E) 拥有博士学位，或曾经/正在从事研究工作，或曾在大学任教的创始人。

(F) 首次创业的非科技背景创业者，且在非科技行业有 10 年以上经验。

(G) 在科技公司任职超过 10 年的科技高管。

(H) 独角兽公司中的工程师/高管（可使用网络上前 1000 家独角兽企业数据辅助判断）。

(I) 在科技公司担任过工程师或产品经理的创始人。

(J) 拥有 MBA 学位的创始人。

(K) 曾在多个国家生活或工作的创业者。

(L) 在当前公司之前，至少已经创办过两家公司的连续创业者。

(M) 来自企业背景，但总经验不足 10 年的创始人。

(N) 具有金融、会计或经济学背景的创始人。

(O) 从艺术/人文学科转向科技创业的创始人。

(P) 在非营利组织或社会创业领域有经验的创始人。

(Q) 曾获得重要奖项或行业认可的创始人（如 Forbes 30 under 30）。

(R) 有军旅背景的创始人。

(S) 在男性主导行业中取得显著成就的女性创始人。

(T) 不属于上述任何类别的其他创始人。

###

尽量避免将创始人归类为 (T)，除非他/她确实不满足其他任何标准。

同时，不要过度乐观；分类必须纯粹基于事实。

每位创始人至少要被分到一个类别；若符合多个类别，也可以赋予多个类别。

为避免幻觉，不要受之前查询影响。

下方以 $$$ 分隔的是一个示例创始人摘要及其分析过程。

输出应当仅为人设列表，例如 “[D, J]”，除此之外不要输出任何其他内容。

'''

A.4 布尔标记提示词

A.4.1 布尔标记打标

'''

请充分理解并分析 ### 中给出的布尔变量，它们分别描述初创企业创始人的不同特征。

这些变量将用于后续对创始人的分类。

###

is_firsttime_founder：若创始人只创办过一家公司，则为 1；若创办过不止一家公司，则为 0。

is_researcher：若创始人在创办公司之前从事过研究工作，则为 1；否则为 0。

is_phd：若创始人在创办公司之前获得博士或同等博士学位，则为 1；否则为 0。

###

你的任务是基于一段创始人书面摘要，为每个变量赋值。

每个变量只能取 0 或 1。

为避免幻觉，不要受之前查询影响。

下方给出一个示例。

最终输出应是一个整数列表，只包含 0 和 1。

对于给定创始人摘要，请进行类似分析，并输出相应整数列表。

'''

注释：[1] Mapping adapted from Xiong and Ihlamur, 2023. [2] 同上。[3] Touvron et al., 2023. [4] 提示词改编自 Vela Partners 的 GitHub。[5] Wang and Ihlamur, 2024. [6] Wei et al., 2023. [7] 提示词改编自 Vela Partners 的 GitHub。[8] Suyal and Ihlamur, 2024. [9] 提示词改编自 Vela Partners 的 GitHub。

该文献的主要观点

本文的核心观点是：大语言模型可以被用于自动化提取创业者特征，并结合机器学习方法提升对创业成功概率的预测能力。作者关注的是风险投资决策中最关键的问题之一，即如何在创业早期识别具有高成长潜力的创始人。由于传统人工判断高度依赖经验、信息处理成本高且标准不统一，本文尝试借助大语言模型，从创始人的 LinkedIn 资料、教育背景、工作经历和创业经历中自动生成结构化特征，再利用这些特征训练机器学习模型，以预测其创办企业未来是否能够达到较高估值或实现重大退出。

文章认为，大语言模型最重要的作用并不是直接给出“投不投”的结论，而是充当一种高效的特征工程工具。具体来说，LLM 被用于生成创始人摘要、划分创业者等级、识别人设类型，并自动标注诸如是否博士、是否有大厂经历、是否曾任高管、是否毕业于顶尖高校等布尔特征。作者发现，这些由 LLM 辅助生成的特征能够揭示某些创始人特征与成功率之间可能存在的联系，例如拥有强技术背景、顶尖高校经历、大科技公司经验，或曾有显著成就的创业者，可能更容易获得成功。此外，在构造了这些特征之后，随机森林、线性回归和 XGBoost 等模型均表现出一定预测能力，这说明 LLM 与传统机器学习结合，能够为 VC 投资分析提供实用的量化支持。

与此同时，本文也传达出一个重要的审慎态度，即自动化创始人评估虽然有应用潜力，但也伴随着显著局限和伦理风险。一方面，文章只基于个人创始人而非完整创始团队进行分析，可能低估联合创始人之间的互补效应；另一方面，LLM 在自动生成标签和人物画像时可能引入偏见，例如文中无监督生成的人设分类中就包含了与性别、军旅

背景等相关的标签，这提示我们，若将此类系统直接用于投资决策，必须建立更严格的校验机制与伦理护栏。

总体而言，本文的主要结论是：LLM 能够显著提高创业者信息处理和特征提取的自动化程度，并与机器学习模型共同构成一种具有现实应用价值的 VC 辅助决策框架；但这一框架目前更适合作为投资判断的辅助工具，而不能替代人工的深度尽调与审慎决策。